# 一种基于 FMCW 的 pacu 患者呼吸状态实时分类方法与系统

## I. 引言

### 1.1 研究背景与问题定义

麻醉复苏室（Post-Anesthesia Care Unit, PACU）是围术期呼吸风险最集中的关键场景之一。患者在拔管恢复阶段通常经历由机控通气向自主呼吸过渡的动态过程，期间可能出现人机不同步、躁动、挣扎等异常状态。若异常状态不能被及时识别，可能增加气道事件与循环波动风险。因此，构建连续、稳定且对异常状态敏感的辅助监测方法，对 PACU 早期风险预警具有重要意义。

当前 PACU 监护主要依赖呼吸机波形、脉搏氧饱和度和呼气末二氧化碳（$CO_2$）等手段。上述方式在临床中具有重要价值，但仍存在一定局限：人工观察难以长期维持高频连续关注；接触式或依赖管路采样的监测方式在体动、护理操作和设备耦合变化条件下可能出现信号波动。相比之下，毫米波雷达具有非接触、可连续采集、对胸腹微动敏感等特点，为 PACU 场景下的辅助呼吸监测提供了新的技术路径。然而，真实病房环境中存在人员走动、床体振动及多径反射等干扰，同时异常事件占比较低，导致模型面临类别不平衡与鲁棒性不足等挑战。

基于上述背景，本文将 PACU 拔管恢复阶段呼吸监测建模为二分类任务：类别 0 为平稳耐受状态（机控呼吸及自主呼吸平稳恢复），类别 1 为异常对抗状态（人机不同步、躁动及挣扎）。在此基础上，针对呼吸微动信号中同时存在的多尺度局部形态特征与长时序依赖关系，本文提出 MS-CNN-Attn-BiLSTM 模型，并进一步构建实时监测系统验证其在线应用可行性。需要说明的是，系统中的空床识别与窒息风险告警属于部署层的安全增强策略，用于提升连续监测中的报警稳定性，不改变本文离线建模的二分类主任务。

### 1.2 相关工作

围术期呼吸监测是 PACU 管理的重要研究方向。已有临床研究表明，连续通气监测有助于早期识别恢复期呼吸抑制与通气异常。Potvin 等[1]在 PACU 成人随机对照研究中评估了连续 capnometry 的临床价值，结果显示其有助于降低恢复期 $CO_2$ 潴留发生率。Langhan 等[2]在儿科 PACU 研究中指出，capnography 对呼吸抑制事件具有较高敏感性，优于仅依赖脉搏氧饱和度的被动识别。Lucas Assunção 等[3]的综述进一步总结了 PACU 护理场景中 capnography 的应用价值与实施障碍。总体而言，该方向以接触式或管路采样式监测为主。

在非接触监测方面，Purnima 等[4]在 PACU 场景探索了热成像呼吸率监测，验证了非接触连续 RR 估计的可行性。与热成像相比，毫米波雷达在弱光环境适应性和隐私友好性方面具有优势。Iyer 等[5]基于 77 GHz FMCW 雷达结合机器学习实现呼吸/心率估计与节律异常检测；Chen 等[6]提出毫米波生命体征高精度检测流程，通过信号处理提升参数估计稳定性；Hao 等[7]进一步构建了雷达

生命体征检测框架，用于非接触呼吸与心率估计。上述研究推动了雷达生命体征感知发展，但任务目标多集中于呼吸率/心率等连续参数估计。

部分研究开始关注雷达呼吸模式识别。Hao 等[8]提出了基于 77 GHz 雷达的呼吸模式分类系统，展示了毫米波在呼吸形态识别中的潜力。然而，该类研究多在实验室或通用场景开展，尚未充分覆盖 PACU 拔管恢复阶段“高噪声、强干扰、类别不平衡”的临床约束。特别是围绕“平稳恢复 vs 异常对抗”这一贴近 PACU 护理决策的状态识别任务，公开研究仍相对有限。

据我们所知，关于“毫米波雷达 + PACU 场景 + 拔管恢复期呼吸状态识别”的系统化研究仍较少，且将离线识别模型与在线报警稳定策略联合验证的工作尚不充分。基于此，本文聚焦 PACU 拔管恢复阶段的状态识别与实时部署：离线阶段构建二分类识别模型，在线阶段引入防抖状态机与安全增强策略，以提升连续监测条件下的临床可用性。

### 1.3 本文贡献与论文结构

本文的主要贡献如下：

1. 面向 PACU 拔管恢复阶段，构建了以“平稳耐受/异常对抗”为核心的呼吸状态识别任务，并建立真实临床连续监测数据评估流程。
2. 提出 MS-CNN-Attn-BiLSTM 模型，通过多尺度卷积、通道注意力与双向时序建模协同提升在高噪声与类别不平衡条件下的识别性能。
3. 设计在线防抖报警机制，在部署端融合物理门控、概率平滑与时序积分策略，降低瞬时干扰导致的告警闪烁。
4. 开发软硬件一体化 PACU 实时监测原型系统，完成从信号采集、在线推理到临床界面显示的闭环验证。

## II. 数据采集与预处理

本节介绍 PACU 场景下毫米波雷达临床数据集的构建过程，包括临床监测场景、设备部署方式、标签定义、数据划分策略以及信号预处理流程。

### A. 临床监测场景与设备部署

本研究数据采集于中国科学技术大学附属第一医院（安徽省立医院）麻醉复苏室（PACU）。受试对象为接受全身麻醉手术并处于拔管恢复期的患者，共纳入 36 名受试者，累计获得有效连续监测数据 9.44 h。所有数据采集过程均遵循

医学伦理要求，并获得患者本人或其家属的知情同意。受试者的人口统计学基线特征见表 1。

本研究采用 Acconeer XE125 60 GHz 脉冲相干毫米波雷达采集患者胸腹部微动信号。考虑到 PACU 中病床布局和设备摆放的复杂性，实验设置了三种具有代表性的雷达部署位姿，分别为 0.7 m 正向（0°）、0.7 m 侧向（45°）以及 1.2 m 正向（0°），以验证系统在不同安装条件下的适用性。雷达通过床旁支架固定，并统一设置采样率为 232 Hz，以保证不同样本之间采样条件的一致性。

**B. 标签定义与数据划分策略**

为获得可靠标签，本研究将雷达时间戳与呼吸机导出的压力、流量和容量波形进行同步对齐，并结合临床观察记录，由专业麻醉医师完成标注。根据患者呼吸状态，将任务定义为二分类：类别 0 为平稳耐受状态，包括机控呼吸及自主呼吸平稳恢复；类别 1 为异常对抗状态，包括人机不同步、躁动及挣扎等情况。

需要说明的是，PACU 拔管恢复期患者大部分时间处于相对平稳的呼吸状态，而呼吸对抗等异常事件发生频率较低，因此原始数据天然存在类别不平衡。对于该类监测任务，数据价值不仅取决于连续监测时长，更取决于是否能够覆盖具有代表性的呼吸状态及其变化过程。为避免数据泄露并客观评估模型对未知患者的泛化能力，本文采用受试者级独立划分（subject-wise split）策略，将 36 名受试者划分为训练集、验证集和测试集。其中，训练集包含 28 名受试者，总时长约 6.87 h；验证集包含 3 名受试者，总时长约 0.88 h；测试集包含 5 名完全独立的受试者，总时长约 1.69 h。

**C. 数据切片与预处理流程**

针对原始雷达回波信号，首先提取复信号相位，并采用 0.05 Hz 零相移高通滤波去除低频基线漂移。随后，利用相位解缠方法恢复胸腹部相对位移序列。为构建统一的模型输入，采用滑动窗口对连续信号进行切片，每个窗口长度设为 15 s。对于训练阶段的少数类异常样本，进一步采用高重叠率滑动窗口进行切片扩增，以增加异常样本数量并缓解类别不平衡问题。

由于系统采样率为 232 Hz，单个 15 s 窗口原始包含 3480 个采样点。考虑到原始时序长度较大，直接输入网络会增加计算复杂度，同时呼吸状态识别主要依赖较低频范围内的动态变化信息，本文对每个窗口进一步进行重采样，将其统一压缩为 435 个采样点，对应等效采样率约为 29 Hz。最后，对重采样后的序列执行 Min-Max 归一化处理，并将其表示为维度为 (1 \times 435) 的一维张量，作为后续模型的标准输入。

**表 1 受试者人口统计学基线特征**

| 临床特征 | 统计数值 |
| --- | --- |
| 总受试人数 | 36 |
| 性别（男 / 女） | 18 / 18 |
| 年**（岁） | 53.1 ± 21.3（范围：3–89） |
| 身高（cm） | 158.9 ± 14.9（范围：94–175） |
| 体重（kg） | 60.5 ± 11.4（范围：14–79） |
| 主要手术类型 | 关节置换、肺叶切除、直肠根治术、前列腺切除等 |

## II. PROPOSED METHODOLOGY (提出的呼吸状态监测方法)

本节介绍本文提出的呼吸状态识别方法。基于第二节所述数据采集与预处理流程，每个样本最终表示为长度为 435 的一维时序信号。针对 PACU 场景下呼吸信号同时具有低频节律变化与短时突发异常的特点，本文构建了一个由多尺度一维卷积、通道注意力机制和双向长短期记忆网络组成的端到端分类模型，以实现对平稳耐受状态与异常对抗状态的自动识别。整体网络结构如图 X 所示。

### A. Clinical Task Definition and Input Representation

根据临床观察及标签定义，本文将 PACU 中患者呼吸状态识别建模为二分类任务。类别 0 表示平稳耐受状态，包括机控呼吸及自主呼吸平稳恢复阶段；类别 1 表示异常对抗状态，包括人机不同步、躁动及挣扎等情况。与平稳耐受状态相比，异常对抗状态通常表现出更明显的局部突变和更复杂的时序波动特征。

在输入构建方面，原始雷达回波经相位提取、高通滤波、相位解缠、滑动窗口分割及归一化处理后，被转换为固定长度的一维时序向量。设单个输入样本表示为

$$X \in R^{C \times L},$$

其中，(C=1) 表示输入通道数，(L=435) 表示时间序列长度。该输入向量作为后续特征提取与时序建模模块的统一输入。

### B. Multi-Scale 1D-CNN Feature Extraction

PACU 场景下的呼吸微动信号具有明显的多尺度特征：一方面，平稳呼吸通常表现为相对缓慢的周期性变化；另一方面，异常对抗事件往往伴随短时间内的快速波动或局部突变。若仅采用单一尺度卷积核进行特征提取，可能难以同时

兼顾长时间尺度趋势信息与短时间尺度局部变化。因此，本文设计了多尺度一维卷积模块，以增强模型对不同时间尺度特征的表达能力。具体而言，模型并行设置两个一维卷积分支，分别采用较大卷积核和较小卷积核对输入信号进行特征提取。较大卷积核用于捕获较长时间范围内的整体变化趋势，较小卷积核则用于提取局部短时变化特征。对于输入信号 (X)，两个分支的特征映射分别表示为

$$F_{large} = \sigma(\mathrm{BN}(W_{large} * X + b_{large}))$$

$$F_{small} = \sigma(\mathrm{BN}(W_{small} * X + b_{small}))$$

其中，(*) 表示一维卷积操作，$W_{large}$和 $W_{small}$ 分别为大尺度卷积核与小尺度卷积核对应的权重参数，$b_{large}$和 $b_{small}$ 为偏置项，$\mathrm{BN}(\cdot)$ 表示批量归一化操作，$(\sigma(\cdot))$表示 ReLU 激活函数。

本文分别采用卷积核大小为 7 和 5 的两个分支进行特征提取，两个分支输出通道数均设置为 32。随后，对各分支输出特征图分别执行最大池化操作，以降低特征维度并抑制局部噪声影响。最后，在通道维度上对两个分支的特征进行拼接，得到融合后的多尺度特征表示：

$$F_{ms} = \mathrm{MaxPool1d}\left(F_{large}\right) \oplus \mathrm{MaxPool1d}(F_{small})$$

其中，$\oplus$表示通道维度的拼接操作。融合后的特征矩阵同时包括了呼吸信号的整体趋势特征与局部异常变化特征，为后续特征重标定和时序建模提供了基础。

## C. Adaptive Channel Attention Mechanism

多尺度卷积模块能够提取不同时间尺度下的特征信息，但在实际 PACU 场景中，雷达信号仍可能受到环境干扰、设备振动及多径效应等因素影响，从而引入冗余特征。若对所有通道赋予相同权重，可能削弱关键信息的表达能力。为此，本文在多尺度卷积模块之后引入通道注意力机制，对不同通道特征进行自适应重标定，以突出更具判别性的特征表示。

设多尺度融合后的特征矩阵为

$$F_{ms} \in R^{2c \times l'}$$

其中，(C'=64) 表示融合后的通道数，(L') 表示池化后的时间长度。首先，采用全局平均池化对每个通道进行压缩，获得通道级统计描述向量 (s)：

$$s_c = \frac{1}{L'}\sum_{i=1}^{L'} F_{ms}(c,i)$$

其中，(s_c) 表示第 (c) 个通道的全局统计量。

随后，利用两层全连接网络对通道描述向量进行非线性映射，生成对应的通道权重：

$$w = \sigma\big(W_2\delta(W_1 s)\big)$$

其中，($W_1$) 和 ($W_2$) 为两层全连接层的权重参数，($\delta(\cdot)$)表示 ReLU 激活函数，($\sigma(\cdot)$) 表示 Sigmoid 函数。本文将通道压缩比设置为 (r=8)，以减少参数量并提高训练稳定性。

最终，将得到的权重向量 (w) 与原始特征矩阵 ($F_{\text{ms}}$) 逐通道相乘，得到重标定后的特征表示：

$$F_{attn} = w \otimes F_{ms}$$

其中，($\otimes$)表示通道维度上的逐元素加权操作。通过该过程，模型能够自适应增强与呼吸状态判别相关的通道响应，减弱冗余或干扰特征的影响。

## D. Bidirectional Temporal Modeling and State Decoding

经过卷积特征提取与通道注意力重标定后，模型已获得较强的局部时序表征能力。然而，仅依赖卷积操作仍难以充分建模长时间范围内的上下文依赖关系。对于 PACU 中的呼吸状态识别任务，异常对抗事件通常不仅体现为局部突变，还表现为在一段时间内持续存在的异常动态模式。因此，本文进一步引入双向长短期记忆网络（BiLSTM）对特征序列进行时序建模。

设经过注意力模块后的特征序列表示为

$$H = [h_1, h_2, \ldots, h_T],$$

其中，(T) 表示序列长度，($h_t$)表示第 (t) 个时间步对应的特征向量。BiLSTM 同时从正向和反向两个方向对序列进行建模，分别得到前向隐藏状态 ($\overrightarrow{v_t}$) 和后向隐藏状态 ($\overleftarrow{v_t}$)。在每个时间步 (t)，双向特征表示可写为

$$v_t = \overrightarrow{v_t} \oplus \overleftarrow{v_t},$$

其中，$(\oplus)$表示向量拼接操作。本文将 BiLSTM 每个方向的隐藏单元数设置为 64，因此拼接后的特征维度为 128。

为了获得固定长度的全局时序表示，本文在 BiLSTM 输出序列上采用全局平均池化操作，将整个时间维度上的特征聚合为单个向量：

$$z_{\text{global}} = \frac{1}{T}\sum_{t=1}^{T} v_t.$$

随后，将全局特征向量输入 Dropout 层以降低过拟合风险，Dropout 失活率设为 0.1。最后，通过全连接层和 Softmax 函数输出样本属于两类呼吸状态的预测概率：

$$\hat{y} = \text{Softmax}(W_{\text{fc}} z_{\text{global}} + b_{\text{fc}}),$$

其中，$(W_{\text{fc}})$ 和$(b_{\text{fc}})$ 分别表示全连接层的权重与偏置，$(\hat{y})$ 表示模型输出的类别概率。

综合而言，本文提出的 MS-CNN-Attn-BiLSTM 模型首先利用多尺度一维卷积提取呼吸信号在不同时间尺度上的局部特征，然后通过通道注意力机制对关键特征进行自适应增强，最后结合 BiLSTM 建模长程时序依赖关系，从而实现对 PACU 场景下平稳耐受状态与异常对抗状态的有效识别。

# IV. EXPERIMENTS AND RESULTS

本节对所提出的 MS-CNN-Attn-BiLSTM 模型在独立测试集上的性能进行评估。首先介绍实验环境与评价指标，随后将所提方法与传统机器学习方法及基础深度学习模型进行对比，并结合 ROC 曲线、PR 曲线及混淆矩阵对模型性能进行进一步分析。

## A. Experimental Setup and Evaluation Metrics

本研究中的深度学习模型均基于 PyTorch 框架实现，并在配备单张 NVIDIA RTX 3090 GPU 的工作站上完成训练。模型训练过程中采用 Adam 优化器，初始学习率设置为 0.001，批大小设为 64，最大训练轮数设为 100。对于二分类任务，采用交叉熵损失函数作为优化目标。验证集用于模型选择与参数调节，测试集仅用于最终性能评估。

为全面评估不同模型的分类性能，本文选取准确率（Accuracy）、精确率（Precision）、召回率（Recall）和 F1-score 作为评价指标。其中，准确率用于衡量模型整体分类正确率；精确率反映被判定为异常样本中真正异常样本所占比例；召回率表示模型对异常状态的识别能力；F1-score 综合考虑精确率与召回率，能够在类别不平衡场景下更客观地评价模型性能。本文将异常状态定义为正类，因此表中报告的 Precision、Recall 和 F1-score 均针对异常类计算。

考虑到 PACU 场景中异常对抗事件发生频率较低，单独使用准确率可能不足以全面反映模型对少数类样本的识别能力。因此，除整体分类指标外，本文进一步结合 PR 曲线与混淆矩阵，从误报与漏报两个方面对模型性能进行分析。

## B. Classification Performance Comparison

为验证所提方法的有效性，本文将 MS-CNN-Attn-BiLSTM 与四种基线方法进行比较，包括两种传统机器学习方法——支持向量机（SVM）和随机森林（Random Forest, RF），以及两种基础深度学习模型——Vanilla 1D-CNN 和 LSTM Baseline。各模型在独立测试集上的性能如表 I 所示。

**Table I. Performance comparison of different methods on the test set**

| Methods | Accuracy (%) | Precision (%) | Recall (%) | F1-Score (%) |
|---|---|---|---|---|
| Vanilla 1D-CNN | 90.07 | 71.32 | 96.84 | 82.14 |
| LSTM Baseline | 86.10 | 63.64 | 95.79 | 76.47 |
| SVM | 91.32 | 75.00 | 94.74 | 83.72 |
| Random Forest | 91.81 | 78.18 | 90.53 | 83.90 |
| Ours (MS-CNN-Attn-BiLSTM) | **98.76** | **96.88** | **97.89** | **97.38** |

从表 I 可以看出，传统机器学习方法在该任务上表现出较强的基线性能，其中 SVM 和随机森林的准确率分别达到 91.32% 和 91.81%。这说明 PACU 呼吸状态信号中存在一定可分性，浅层分类器能够捕获部分判别特征。相比之下，两种基础深度学习模型的表现并未稳定优于传统机器学习方法，其中 LSTM Baseline 的准确率为 86.10%，低于 SVM 和随机森林。该结果表明，在受试者数量有限且信号存在噪声干扰的条件下，简单深度学习结构难以充分建模稳定的判别模式。

进一步分析可见，Vanilla 1D-CNN 和 LSTM Baseline 均取得了较高的召回率，分别为 96.84% 和 95.79%，但其精确率相对较低，尤其是 LSTM Baseline 的精确率仅为 63.64%。这表明基础深度学习模型虽然能够检出大部分异常样本，但同时也产生了较多误报。相比之下，所提出的 MS-CNN-Attn-BiLSTM 在准确率、精确率、召回率和 F1-score 四项指标上均取得最佳结果，分别达到 98.76%、96.88%、97.89% 和 97.38%。这一结果说明，所提方法在保持较高异常检出能力的同时，能够有效降低误报率，从而在整体分类性能上优于其他对比模型。

从模型结构上看，该性能提升主要得益于以下三个方面：首先，多尺度卷积模块能够同时提取呼吸信号中的长时间尺度趋势特征和短时间尺度局部变化特征；其次，通道注意力机制能够增强与呼吸状态判别相关的特征响应，并抑制噪声与冗余信息的影响；最后，BiLSTM 模块进一步建模了特征序列的双向时序依赖关系，从而提高了模型对持续性异常模式与瞬态干扰之间的区分能力。三者结合，使模型在复杂 PACU 场景下获得了更稳定的判别性能。

## C. ROC, PR Curves, and Confusion Matrix Analysis

为了进一步分析各模型在类别不平衡条件下的分类特性，本文绘制了 ROC 曲线、PR 曲线以及混淆矩阵，如图 2 和图 3 所示。

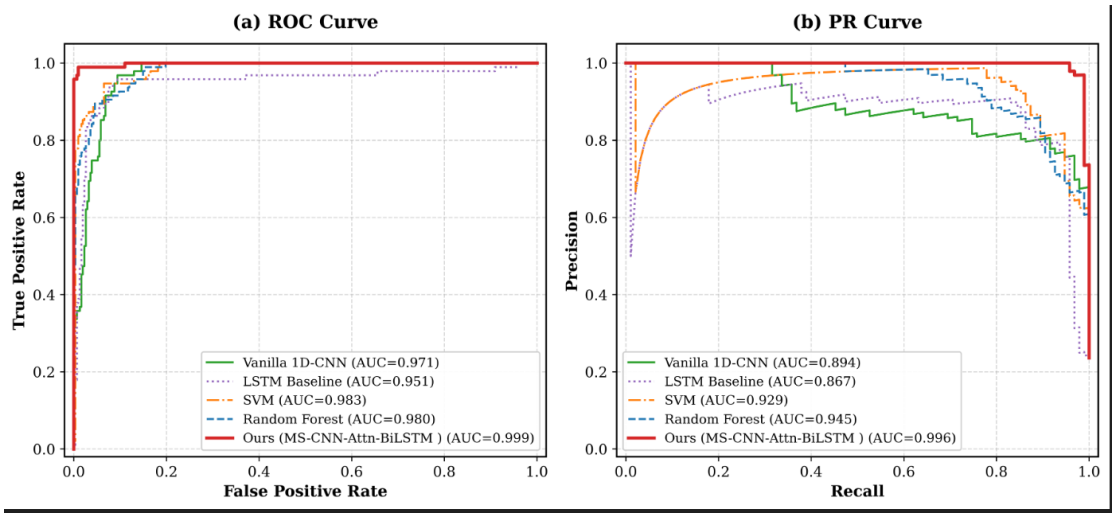


从图 2(a) 可以看出，各模型均取得了较高的 ROC 曲线下面积（AUC），其中所提出模型的 ROC AUC 为 0.999，高于 Vanilla 1D-CNN（0.971）、LSTM Baseline（0.951）、SVM（0.983）和 Random Forest（0.980）。这表明所提出模型在不同分类阈值下具有更优的整体区分能力。

然而，在类别不平衡场景下，仅依赖 ROC 曲线可能无法充分反映模型对少数类样本的识别性能，因此本文进一步考察 PR 曲线。如图 2(b) 所示，MS-CNN-Attn-BiLSTM 的 PR AUC 达到 0.996，明显高于 Vanilla 1D-CNN

（0.894）、LSTM Baseline（0.867）、SVM（0.929）和 Random Forest（0.945）。这一结果说明，与其他模型相比，所提方法在提高异常状态检出率的同时，能够更好地保持精确率，因此在少数类识别方面表现出更优的稳定性。

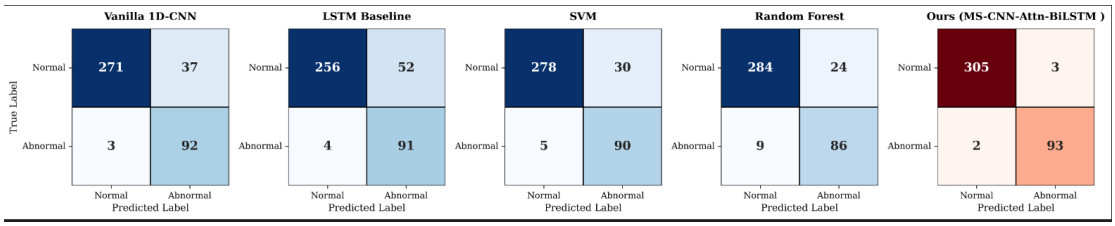


图 3 给出了不同模型在测试集上的混淆矩阵。对于所提出方法，正常类样本中有 305 个被正确分类，仅有 3 个被误判为异常；异常类样本中有 93 个被正确识别，仅有 2 个被误判为正常。相比之下，Vanilla 1D-CNN 和 LSTM Baseline 虽然具有较高的异常召回率，但产生了更多假阳性样本；SVM 和随机森林在整体表现上较为稳定，但对异常类样本的识别能力仍略低于所提出方法。混淆矩阵分析结果与表 I 及图 2 的结论一致，即所提出模型在误报与漏报之间取得了更优平衡。

综合以上结果可以看出，MS-CNN-Attn-BiLSTM 在独立测试集上表现出最优的综合性能。与传统机器学习模型相比，其在保持较高召回率的同时进一步提升了精确率；与基础深度学习模型相比，其在减少误报方面表现出明显优势。这表明所提出模型更适合用于 PACU 场景下的呼吸状态自动识别任务，尽管所提方法在当前数据集上取得了较优结果，其泛化能力仍有待在更大规模、多中心临床数据上进一步验证。

## V. 面向 PACU 场景的实时呼吸监测系统实现

为验证所提算法在真实 PACU 场景中的在线应用可行性，本文在离线模型基础上开发了软硬件一体化的非接触式实时监测系统。系统实现了从毫米波雷达信号采集、在线预处理、模型推理到状态显示与报警输出的完整闭环，并针对临床连续监护中的误报抖动问题设计了多级防抖策略。

**5.1 系统架构与在线数据流** 系统采用三层架构：硬件感知层、边缘推理层和临床交互层。硬件感知层使用 60 GHz 毫米波雷达采集胸腹部微动信号；边缘推理层在床旁工作站完成信号预处理与 MS-CNN-Attn-BiLSTM 在线推理；临床交互层负责状态可视化与报警反馈。系统整体架构如图 5-1 所示。

为与前文实验设置保持一致，采集端扫描速率设置为 232 Hz，并通过帧级聚合输出约 29 Hz 的连续时序数据。数据流转层采用双缓冲与滑动窗口机制：内存中维护长度为 15 s 的先进先出队列（约 435 帧），以 1 s 步长更新窗口并触发推理。该机制将采集线程与推理线程解耦，降低线程阻塞风险，能够支持连续流数据下的稳定在线运行。针对不同探测距离，系统可调用预设参数配置，实现近场与远场条件下的自适应采集。

**5.2 基于多级防抖状态机的报警决策** 在真实 PACU 环境中，医护走动、床体振动及短时体动均可能导致瞬时异常响应。若直接依据单窗口输出报警，容易出现告警闪烁并影响临床可用性。为此，本文在模型输出端构建了融合物理门控与时序决策的防抖状态机，将连续推理结果映射为平稳耐受、异常对抗、窒息风险和脱接/空床四类状态。

首先，系统引入基于回波能量的物理门控策略。实时计算单帧空间能量，当能量低于空床阈值时优先判定为“脱接/空床”状态，并重置风险积分，以降低空床噪声引发的误报传播。其次，对模型输出概率进行指数移动平均（EMA）平滑，并采用迟滞阈值机制（触发阈值与解除阈值分离）进行状态切换，从而抑制单次概率毛刺导致的瞬时告警。再次，对于高风险状态，系统采用短时积分确认策略：仅当高风险证据在连续时间窗内累积达到设定条件时才触发报警；在恢复阶段，当微动幅度与频域特征满足恢复判据时，执行加速冲刷以平滑退出报警状态。该策略能够在维持异常检出能力的同时减少不必要告警。

上述阈值及状态机参数均通过验证集调参与在线联调确定。通过“物理门控—概率平滑—时序积分”三级策略，系统在连续运行中实现了较稳定的报警输出，为临床部署提供了工程可行性支撑。

**5.3 面向临床可用性的交互界面设计** 为提升 PACU 高压场景下的信息获取效率，系统前端采用临床可用性导向的界面设计（见图 5-2）。在交互布局上，界面划分为三个核心区域：左侧为呼吸微动趋势显示区，用于提供连续时序参考；底部为状态时间轴，用于回溯近期状态变化；右侧为高可视权重的监测看板（Medical HUD），集中显示当前离散状态、风险概率及信号质量指标。

与传统以原始波形为中心的界面不同，本文界面弱化中间调试特征与冗余曲线，优先突出与临床决策直接相关的状态信息，降低信息过载。波形区仅保留必要的趋势表达，用于辅助人工复核；关键判定结果通过高对比度文本与颜色编码呈现，便于医护人员在短时间内完成状态识别。结合前述防抖报警策略，系统能够在连续监测条件下提供更稳定、可解释的状态输出，完成了算法从离线评估到在线应用的有效转化。